Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский университет
«Московский институт электронной техники»

Кафедра Высшая математика 1

Гречишкин Денис Андреевич

Бакалаврская работа
По направлению 01.03.04 «Прикладная математика»
(бакалавриат)

Исследование затухающего Dropout для нейросетей, ориентированных на решение задач классификации.

Студент _____ Гречишкин Д.А.

Руководитель ВКР _____ Назаров М.Н.

Москва 2026

АННОТАЦИЯ

Данная выпускная квалификационная работа (ВКР) посвящена исследованию затухающего Dropout для нейросетей, ориентированных на решение задач классификации.

Объектом исследования выступает модель нейронной сети с использованием затухающего Dropout. Особое внимание уделено потерям, полученным в результате обучения нейронной сети при различных функциях изменения вероятности отключения нейронов в слоях Dropout.

Структура работы включает в себя:

- Введение с обоснованием актуальности работы
- Теоретическую часть с описанием
- Практическую часть с исследованием
- Заключение с выводом о проделанной работе и дальнейшем развитием задачи

ОГЛАВЛЕНИЕ

АННОТАЦИЯ 2
1. ВВЕДЕНИЕ 4
1.1. Обоснование выбора метода исследования 4
1.2. Цель и задачи исследования 7
1.3. Требования к результатам работы. 7
2. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ 9
3. ПРАКТИЧЕСКАЯ ЧАСТЬ 15
3.1. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели классификации текстов. 15
3.2. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели бинарной классификации изображений. 21
3.3. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели многоклассовой классификации изображений. 27
3.4. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели классификации звуков. 33
4. ЗАКЛЮЧЕНИЕ 39
5. СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ 40

1. ВВЕДЕНИЕ

1.1. Обоснование выбора метода исследования

В моделях любых типов и с любым набором данных процесс обучения можно разделить на три фазы:

1. Недообучение: на этом этапе модель ещё не «выучила» основные закономерности в данных, ошибка как на обучающих, так и на тестовых данных стабильно убывает

2. Зона надежного обучения: в этой зоне модель наиболее эффективно извлекает значимые закономерности, игнорируя случайный шум. Достигается компромисс: модель хорошо описывает обучающие данные и обобщает на новые примеры.

3. Переобучение: на этом этапе потери на обучающих данных продолжают снижаться, а на проверочных – перестают улучшаться или даже растут. Модель начинает «запоминать» шум.

Целью обучения является зафиксировать модель в этой фазе.

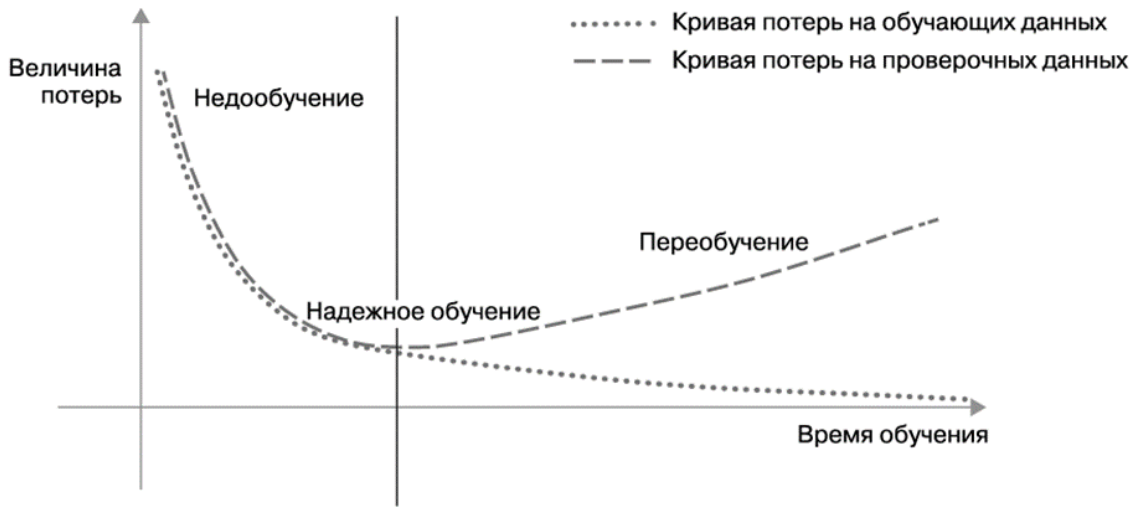


Рисунок 1. Этапы обучения на графике величины потерь от времени обучения

Суть борьбы с переобучением состоит в том, чтобы принудительно ограничить «свободу» модели для того чтобы сместить её фокус с запоминания частных примеров на изучение статистически значимых паттернов. То есть борьба с переобучением – это поиск баланса между минимизацией ошибки на обучающих

данных и качеством работы на новых, ранее не виденных данных. Приемы, мешающие модели достичь идеального соответствия обучающим данным, чтобы улучшить ее качество на проверочных данных называются методами регуляризации.

Существует несколько распространенных методов регуляризации:

1. Уменьшение размера сети: известно, что слишком маленькие модели не подвержены переобучению. Поэтому самый простой способ предотвратить переобучение — уменьшить размер модели, т.е. количество изучаемых параметров в модели (определяется количеством слоев и количеством нейронов в каждом слое) Модель с ограниченными ресурсами не сможет просто запомнить обучающие данные, поэтому для минимизации потерь ей придется прибегнуть к изучению сжатых представлений, обладающих прогнозирующей способностью в отношении целей – это нам как раз и требуется. Но в то же время модель должна иметь достаточное количество параметров, чтобы не возник эффект недообучения, поэтому важно найти компромисс между слишком большой и недостаточной емкостью.

2. Добавление регуляризации весов: её суть заключается в том, что более простые модели менее склонны к переобучению, чем сложные. Простая модель в данном контексте – это модель, в которой распределение значений параметров имеет меньшую энтропию (или модель с меньшим числом параметров, как было показано в предыдущем разделе). То есть типичный способ смягчения проблемы переобучения заключается в уменьшении сложности модели путем ограничения значений ее весовых коэффициентов, что делает их распределение более равномерным. Этот прием называется регуляризацией весов. Он реализуется добавлением в функцию потерь штрафа за увеличение весов и имеет две разновидности, такие как:

- L1-регуляризация (L1 regularization) — добавляемый штраф прямо пропорционален абсолютным значениям весовых коэффициентов (L1-норма весов);
- L2-регуляризация (L2 regularization) — добавляемый штраф пропорционален квадратам значений весовых коэффициентов (L2-норма весов). В контексте нейронных сетей L2-регуляризация также называется сокращением весов.

Это два разных названия одного и того же явления: сокращение весов с математической точки зрения есть то же самое, что L2-регуляризация.

3. Добавление прореживания (Dropout) – самый популярный метод регуляризации. Заключается он в том, что во время обучения Dropout случайным образом обнуляет (исключает) часть нейронов (и их связи) в слое - с заданной вероятностью p (коэффициентом прореживания – долью отключаемых нейронов). Во время обучения в выходном векторе, полученном при прохождении вектора входных данных через слой с прореживанием, обнуляются те компоненты, которые получились в результате преобразования отключенных нейронов. Например, если в процессе обучения некоторый слой для некоторого входного образца в нормальной ситуации возвращает вектор [0.2, 0.5, 1.3, 0.8, 1.1], то после прореживания некоторые элементы вектора получают нулевое значение: например [0, 0.5, 1.3, 0, 1.1]. Обнуляемые значения вектора вносят стохастический шум.

На этапе тестирования все нейроны активны, но их веса корректируются для компенсации. Делается это для того чтобы сеть не полагалась на фиксированные комбинации нейронов, а училась избыточным, более устойчивым представлениям данных.

Классическое прореживание стало очень популярным для регуляризации нейронной сети. В классическом прореживании вероятность отключения нейронов остается постоянной на протяжении всего процесса. Однако применение фиксированной вероятности на протяжении всего процесса обучения имеет свои недостатки. (можно попробовать переписать)

На финальных эпохах, когда модель переходит к стадии тонкой настройки весовых коэффициентов, постоянное отключение нейронов увеличивает дисперсию градиентов. Это вызывает осцилляции функции потерь вблизи оптимума и препятствует точной сходимости алгоритма.

Поэтому для решения описанной проблемы был предложен метод затухающего прореживания. В рамках данного подхода вероятность отключения нейронов p постепенно уменьшается по мере увеличения числа пройденных эпох. Переход к динамическому, монотонно-убывающему изменению вероятности отключения нейронов позволяет сохранить регуляризующий эффект в начале обучения и обеспечить стабильную сходимость модели на его завершающих этапах.

1.2. Цель и задачи исследования

Цель исследования: проанализировать и сравнить влияния различных монотонно-убывающих функций затухающего прореживания на эффективность и стабильность обучения нейронных сетей в задачах классификации данных различного рода.

Для достижения поставленной цели были сформулированы и решены следующие задачи:

1) Ввести в рассмотрение группу задач классификации различных, группу монотонно-убывающих функций с коэффициентом затухания k, начальную и конечную вероятности прореживания, а также число эпох.

2) Сформулировать аналитические выражения для четырех групп монотонно-убывающих функций, описывающих изменение вероятности прореживания нейронов и определить условия для расчета допустимых границ коэффициента затухания k.

3) Разработать программные модули подготовки данных и конструирования архитектур нейронных сетей для четырех задач классификации данных.

4) Для каждой задачи классификации данных осуществить серию вычислительных экспериментов по обучению нейронных сетей с применением заданных функций затухающего прореживания на заданном диапазоне значений параметра k.

5) Для каждой задачи классификации данных вычислить математическое ожидание и среднеквадратичное отклонение функции потерь на валидационных данных и определить оптимальный коэффициент затухания для каждой группы функций.

6) Для каждой задачи классификации провести итоговое сопоставление минимальных достигнутых значений функции потерь для всех исследуемых законов затухания и выявить наиболее эффективный метод динамической регуляризации.

1.3. Требования к результатам работы.

Для успешного достижения цели и решения поставленных задач, к результатам исследования предъявляются следующие требования:

1. Требования к математическим результатам:

- Должны быть получены строгие аналитические решения или численные оценки для определения границ интервала $[k_0, k_1]$ коэффициента затухания для каждой из четырех групп функций.
- Расчетные значения должны гарантировать строгое соблюдение граничных условий: на первой эпохе функция вероятности прореживания должна равняться начальной вероятности прореживания, а на последней эпохе функция вероятности прореживания должна равняться конечной вероятности прореживания.

2. Требования к программной реализации:

- Разработанные программные модули должны обеспечивать полный цикл машинного обучения.
- Программа должна включать реализацию Dropout-слоя, поддерживающую динамическое изменение вероятности прореживания $P(n, k)$ на каждой эпохе n, согласно заданным математическим законам
- Программа должна поддерживать автоматизированный запуск серии из 4 независимых экспериментов для каждой конфигурации параметров.

3. Требования к экспериментальным результатам:

- Для каждого набора параметров должны быть вычислены математическое ожидание $M[Loss]$ и среднеквадратичное отклонение $\sigma[Loss]$ функции потерь на валидационной выборке
- Оценка эффективности модели должна обязательно учитывать фактор стабильности обучения посредством расчета целевой функции $J(k)$

4. Требования к аналитическим результатам:

- Для каждого из четырех задач затухания должно быть определено оптимальное значение коэффициента k_0^* минимизирующее целевую функцию $J(k)$.

2. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

2.1. Введение в эксперимент.

В рамках моего исследования было рассмотрено четыре задачи классификации с применением следующих датасетов:

- Задача классификации текстовых данных с использованием датасета, состоящего из рецензий на фильмы
- Задача бинарной классификации изображений с использованием датасета изображений кошек и собак.
- Задача многоклассовой классификации изображений с использованием датасета изображений цветов.
- Задача многоклассовой классификации аудиоданных с использованием датасета коротких голосовых команд.

Для каждой из перечисленных задач разработан программный модуль, обеспечивающий загрузку данных, конструирование соответствующей модели нейронной сети и проведение серии из четырех экспериментов по ее обучению. В качестве итоговых метрик качества для каждой задачи вычисляются математическое ожидание $M[Loss](k_{0j}, P_i)$ и среднеквадратичное отклонение $\sigma[Loss](k_{0j}, P_i)$ функции потерь.

Центральным аспектом исследования является анализ влияния регуляризации методом затухающего прореживания в процессе обучения. С этой целью вводится в рассмотрение семейство монотонно-убывающих функций, определяющих вероятность прореживания нейронов $P(n, k)$ в зависимости от номера эпохи n.

В рамках моего исследования было рассмотрено четыре группы монотонно-убывающих функций:

1) Группа линейных функций:

$$P_1(n, k) = p_{start} - k \cdot n$$

2) Группа полиномиальных функций:

$$P_2(n, k) = p_{start} - k \cdot n^2$$

3) Группа логарифмических функций:

$$P_3(n,k) = p_{start} - k \cdot \log_2(n+1)$$

4) Группа экспоненциальных функций:

$$P_4(n,k) = p_{start} \cdot e^{-k \cdot n}$$

где:

- $p_{start} = 0{,}5$ – начальная вероятность прореживания
- $p_{end} = 0{,}1$ – конечная вероятность прореживания
- $n \in \{1, 2, \dots, 30\}$ – номер эпохи
- $k \in R$ $(k > 0)$ – коэффициент затухания, определяющий скорость убывания функции

Параметры были выбраны исходя из следующей логики. Удаление слишком большого числа нейронов (то есть $P(n,k) > 0{,}5$) разрушает способность сети к обучению, а значение 0,5 является верхней границей, которая максимизирует регуляризационный эффект. При этом, минимальным оптимальным балансом между предотвращением переобучения и сохранением текстового контекста является значение равное 0,1. Количество эпох было выбрано равным 30, так как при таком количестве эпох все рассматриваемые задачи проходят полный цикл обучения.

Методология экспериментального исследования для каждого датасета и каждой группы функций $P_i(n,k)$ $i \in \{1,2,3,4\}$ включает следующие этапы:

1) Определение допустимого диапазона коэффициента затухания $k \in [k_0, k_1]$.

Границы интервала находятся из условий, гарантирующих, что значения функции на всем протяжении обучения не выходят за пределы $[k_{end}, k_{start}]$. В силу монотонного характера предложенных функций, достаточно потребовать, чтобы на первой эпохе вероятность прореживания равнялась p_{start}, а на последней – p_{end}.

Таким образом, значения k_0 и k_1определяются из следующей системы уравнений:

$$\begin{cases} P_i(1, k_0) = p_{start} \\ P_i(30, k_1) = p_{end} \end{cases}$$

2) Выбор параметров k_{0j} из найденного диапазона $[k_0, k_1]$.

Из полученного интервала $[k_0, k_1]$ выбирается набор из 5 равномерно распределенных значений k_{0j} $(j = 1, 2, 3, 4, 5)$.

В случае, если нижняя граница интервала $k_0 = 0$, что соответствует отсутствию затухания и вырожденному режиму регуляризации с фиксированной вероятностью p_{start} данная точка исключается из рассмотрения как тривиальная. Тогда совокупность тестируемых значений k_{0j} формируется путем равномерного разбиения полуинтервала $(k_0, k_1]$ на пять отрезков с шагом $\Delta k = \frac{k_1 - k_0}{5}$:

$$k_{0j} = k_0 + j \cdot \Delta k$$

$$j = 1, 2, 3, 4, 5$$

После этого для каждого k_{0j} производится обучение модели (4 независимых запуска). По итогам запусков на валидационной выборке вычисляются математическое ожидание потерь $M[Loss](k_{0j}, P_i)$ и их среднеквадратичное отклонение $\sigma[Loss](k_{0j}, P_i)$.

3) Отбор оптимального параметра.

Для оценки качества работы модели и учета возможного отклонения была введена целевая функция (функция штрафа) $J(k)$ Значение функции для каждого тестируемого параметра вычисляется как:

$$J(k_{0j}) = \ M[Loss](k_{0j}, P_i) + \sigma[Loss](k_{0j}, P_i)$$

Для каждой группы функций P_i в качестве оптимального выбирается такое значение k_0^* при котором $J(k_0^*) = \min_j J(k_{0j})$.

Так как главной целью исследования является анализ влияния различных монотонно-убывающих функций прореживания на эффективность и стабильность обучения, 5 точек обеспечивают оптимальный баланс между репрезентативностью результатов и вычислительными затратами.

4) Сравнительный анализ.

Проводится сопоставление минимальных достигнутых значений функции потерь для всех четырех групп функций с целью выявления функции затухания, обеспечивающей наилучшее регуляризующее воздействие.

Допустим, что потери в каждом отдельном эксперименте (на определенном датасете и при определенной функции прореживания) имеет нормальное распределение. Это допущение можно сделать на основании того, что финальное значение функции потерь одиночного запуска формируется как результат воздействия множества независимых стохастических факторов на протяжении всего процесса обучения, а именно:

- Случайная инициализация параметров сети – начальные значения весов и смещений генерируются случайным образом перед началом обучения, что задаёт уникальную точку старта для каждого запуска;
- Стохастичность оптимизации – градиентный спуск выполняется на случайных мини-батчах, порядок которых определяется перемешиванием обучающей выборки на каждой эпохе;
- Сам алгоритм регуляризации – механизм прореживания случайным образом деактивирует часть нейронов на каждом шаге прямого и обратного прохода.

В результате воздействия этих случайных факторов из центральной предельной теореме следует, что распределение случайной величины потерь в отдельном эксперименте близко к нормальному. Тогда, исходя их предположения, распределение случайной величины среднего арифметического потерь на четырёх экспериментах также будет нормальным. Следовательно:

$$P\{Loss \leq J\} = P\{\text{ Loss} \leq\ M[Loss] + \lambda \cdot \sigma[Loss]\} = P\left\{\frac{Loss - M[Loss]}{\sigma[Loss]} \leq \lambda\right\} = \Phi(\lambda) =$$

$$= \Phi(1) \approx 0{,}84$$

То есть с вероятностью 0,84 потери будут ниже целевой функции.

Проведем расчет граничных значений для каждого из вида функций.

1. Для линейных функций: $P_1(n,k) = 0{,}5 - nk$

- $P_1(1,k_0) = p_{start}$

  $0{,}5 - k_0 = 0{,}5$

  $k_0 = 0$

  $P_1(30,k_1) = p_{end}$

  $0{,}5 - 30k_1 = 0{,}1$

  $30k_1 = 0{,}4$

  $k_1 \approx 0{,}013$

Искомый отрезок $[k_0, k_1]$ для линейных функций: [0; 0,013]

Рассматриваемые значения k_{0j}:

- $k_{01} = 0{,}0026$
- $k_{02} = 0{,}0052$
- $k_{03} = 0{,}0078$
- $k_{04} = 0{,}0104$
- $k_{05} = 0{,}013$

2. Для полиномиальных функций: $P_2(n,k) = 0{,}5 - n^2k$

- $P_2(1,k_0) = p_{start}$

  $0{,}5 - k_0 = 0{,}5$

  $k_0 = 0$

  $P_2(30,k_1) = p_{end}$

  $0{,}5 - 900k_1 = 0{,}1$

  $900k_1 = 0{,}4$

  $k_1 \approx 0{,}0004$

Искомый отрезок $[k_0, k_1]$ для полиномиальных функций: [0; 0,0004]

Рассматриваемые значения k_{0j}:

- $k_{01} = 0{,}00008$
- $k_{02} = 0{,}00016$
- $k_{03} = 0{,}00024$
- $k_{04} = 0{,}00032$
- $k_{05} = 0{,}00040$

3. Для логарифмических функций: $P_3(n,k) = 0{,}5 - k \cdot \log_2(n+1)$

- $P_3(1,k_0) = p_{start}$

  $0{,}5 - k_0 = 0{,}5$

  $k_0 = 0$

  $P_1(30,k_1) = p_{end}$

  $0{,}5 - k_1\log_2(31) = 0{,}1$

  $k_1\log_2(31) = 0{,}4$

  $k_1 \approx 0{,}08$

Искомый отрезок $[k_0, k_1]$ для логарифмических функций: [0; 0,08]

Рассматриваемые значения k_{0j}:

- $k_{01} = 0{,}016$
- $k_{02} = 0{,}032$
- $k_{03} = 0{,}048$
- $k_{04} = 0{,}064$
- $k_{05} = 0{,}080$

4. Для экспоненциальных функций: $P_4(n,k) = 0{,}5e^{-k\cdot n}$

- $P_1(1,k_0) = p_{start}$

  $0{,}5e^{-k_0} = 0{,}5$

  $k_0 = 0$

  $P_1(30,k_1) = p_{end}$

  $0{,}5\, e^{-30k_1} = 0{,}1$

  $-30k_1 = \ln 0{,}2$

  $k_1 \approx 0{,}05$

Искомый отрезок $[k_0, k_1]$ для экспоненциальных функций: [0; 0,05]

Рассматриваемые значения k_{0j}:

- $k_{01} = 0{,}01$
- $k_{02} = 0{,}02$
- $k_{03} = 0{,}03$
- $k_{04} = 0{,}04$
- $k_{05} = 0{,}05$

3. ПРАКТИЧЕСКАЯ ЧАСТЬ

3.1. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели классификации текстов.

Для классификации текстов использовалась LSTM-модель. Модель состоит из трех слоев. Входной слой имеет вид Dense, состоит из 1024 нейронов, имеет активационную функцию вида Relu, а также нейроны в нем могут отключаться с начальной вероятностью $p_{start} = 0{,}5$; которая потом убывает по одной из упомянутых в п.3. функции. Второй слой также имеет Dense, состоит из 512 нейронов и имеет функцию активации вида Relu. Последний, выходной слой также имеет вид Dense, число нейронов в нем равно количеству уникальных жанров фильма, а активационная функция имеет вид Sigmoid.

Функция потерь в этой модели имеет вид ‘binary_crossentropy’, а алгоритм оптимизации весов нейросети имеет вид ‘RMSprop’ со скоростью обучения learning_rate=0.001 (алгоритм оптимизации представляет собой метод градиентного спуска в которой коэффициент убывания изначально равен learning_rate, а по мере обучения меняется для каждого отдельного веса)

Далее значение k при котором целевая функция (оценка) получилась минимальной будет выделена зеленым цветом

3.1.1. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием линейной функции

$P(n,k) = 0{,}5 - nk$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}0026$	0,3092	0,0022	0,3114
$k = 0{,}0052$	0,3095	0,002	0,3115
$k = 0{,}0078$	0,3092	0,0025	0,3117
$k = 0{,}0104$	0,3096	0,0021	0,3117
$k = 0{,}0013$	0,3094	0,0021	0,3115

Таблица 1. Результаты потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

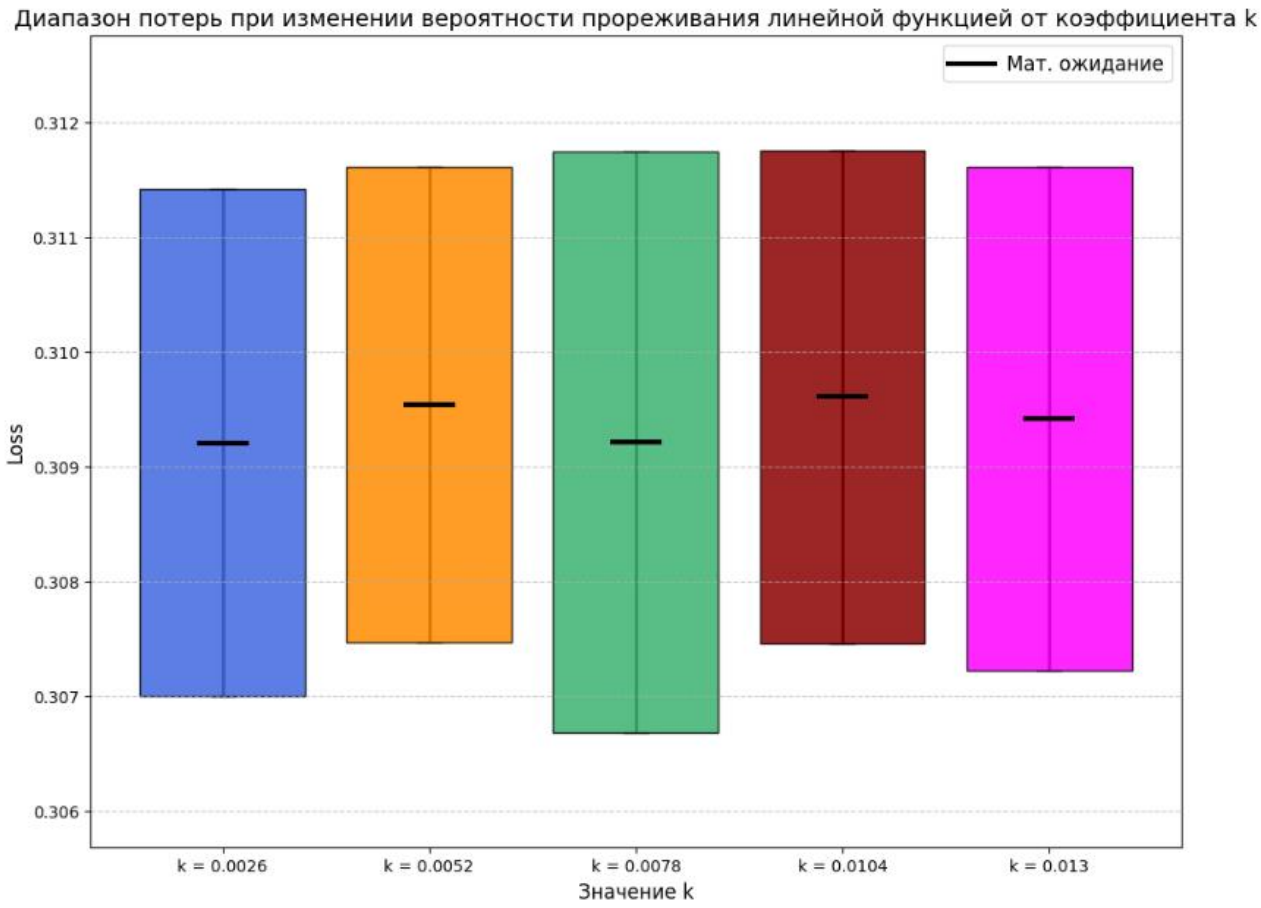


Рисунок 2. Гистограммы потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

Промежуточный вывод к п. 3.1.1: из табл. 1 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}0026$. Это-же видно на гистограмме на рис. 2: значения потерь J при k = 0,0026 и при k = 0,0078 получились близки друг к другу, но с учетом того, что дисперсия при k = 0,0078 получилась выше, то предпочтительнее в дальнейшем рассматривать коэффициент $k_0^* = 0{,}0026$

3.1.2. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием полиномиальной функции

$P(n,k) = 0{,}5 - n^2 k$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}00008$	0,3096	0,0026	0,3122
$k = 0{,}00016$	0,3099	0,0027	0,3126
$k = 0{,}00024$	0,3099	0,0026	0,3125
$k = 0{,}00032$	0,3093	0,0024	0,3117

$k = 0{,}0004$	0,3095	0,0027	0,3122

Таблица 2. Результаты потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

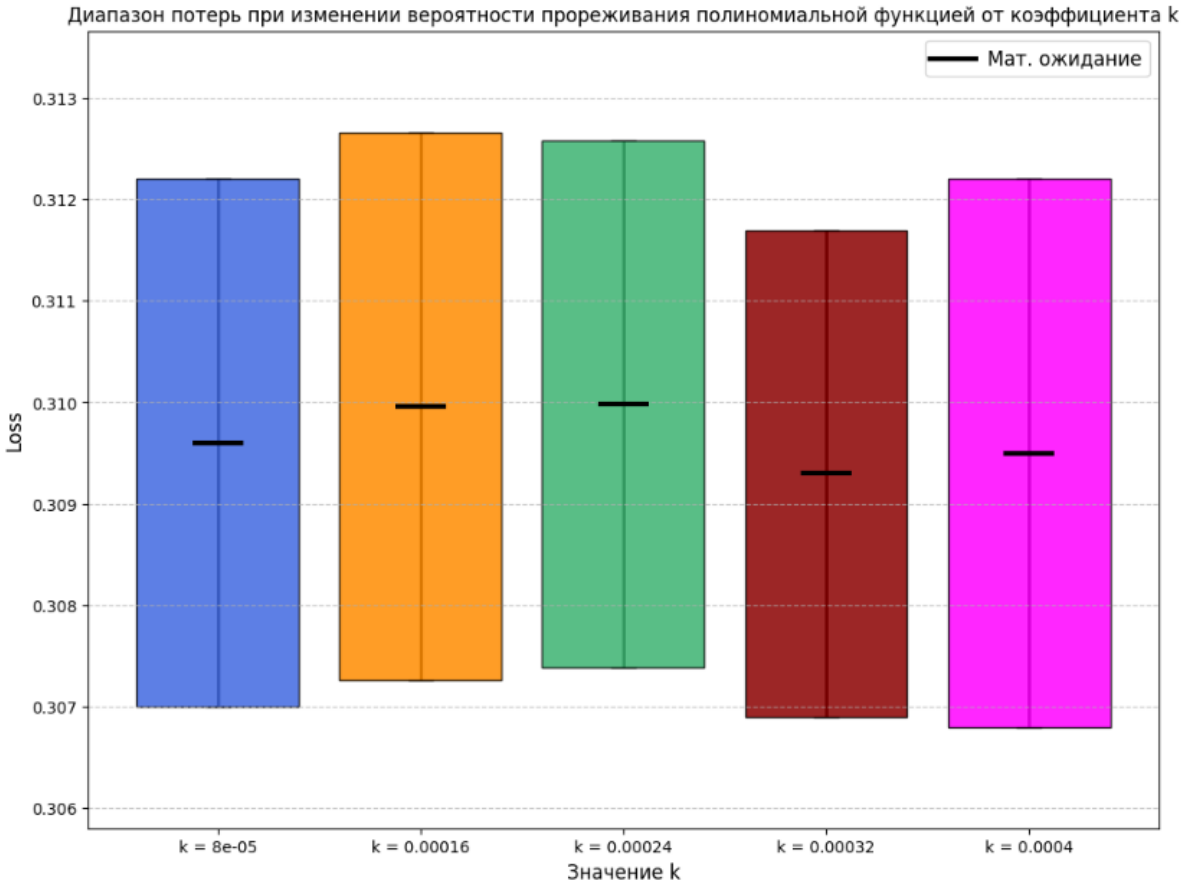


Рисунок 3. Гистограммы потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

Промежуточный вывод к п. 3.1.2: из табл. 2 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}00032$, что подтверждается гистограммой на рис. 3.

3.1.3. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием логарифмической функции.

$P(n,k) = 0{,}5 - k \cdot \log_2(n+1)$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}016$	0,3097	0,0026	0,3123
$k = 0{,}032$	0,3099	0,0016	0,3115

$k = 0{,}048$	0,3095	0,0023	0,3118
$k = 0{,}064$	0,3101	0,0022	0,3123
$k = 0{,}08$	0,3094	0,0026	0,3120

Таблица 3. Результаты потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

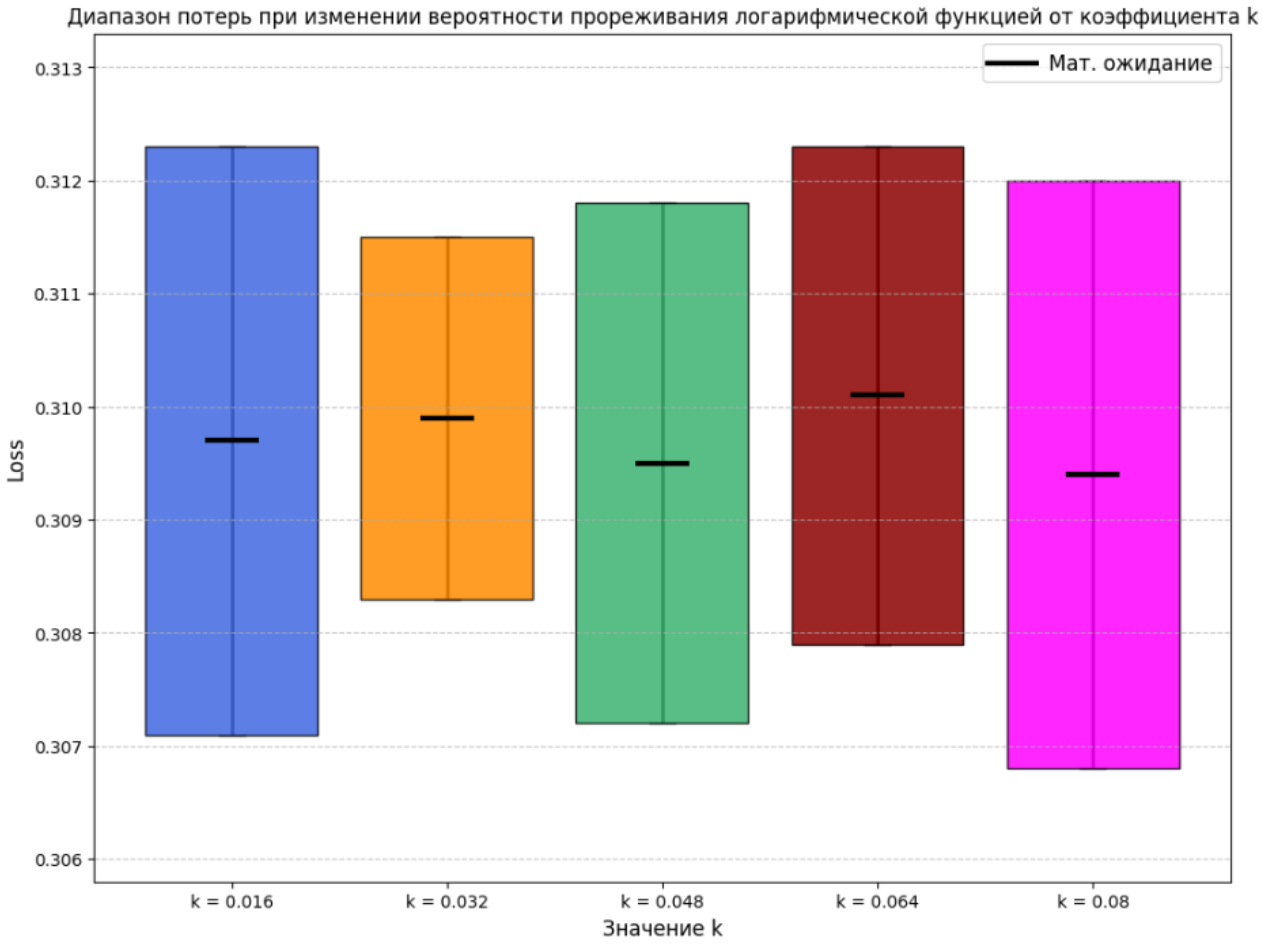


Рисунок 4. Гистограммы потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

Промежуточный вывод к п. 3.1.3: из табл. 3 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}048$. Это-же видно на гистограмме на рис. 4: значения потерь J при k = 0,048 и при k = 0,08 получились близки друг к другу, но с учетом того, что дисперсия при k = 0,048 получилась выше, то предпочтительнее в дальнейшем рассматривать коэффициент $k_0^* = 0{,}048$

3.1.4. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием экспоненциальной функции.

$P(n,k) = 0{,}5e^{-k \cdot n}$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}01$	0,3084	0,0025	0,3109
$k = 0{,}02$	0,3096	0,0028	0,3124
$k = 0{,}03$	0,3098	0,0028	0,3126
$k = 0{,}04$	0,3087	0,0024	0,3111
$k = 0{,}05$	0,3095	0,0018	0,3113

Таблица 4. Результаты потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

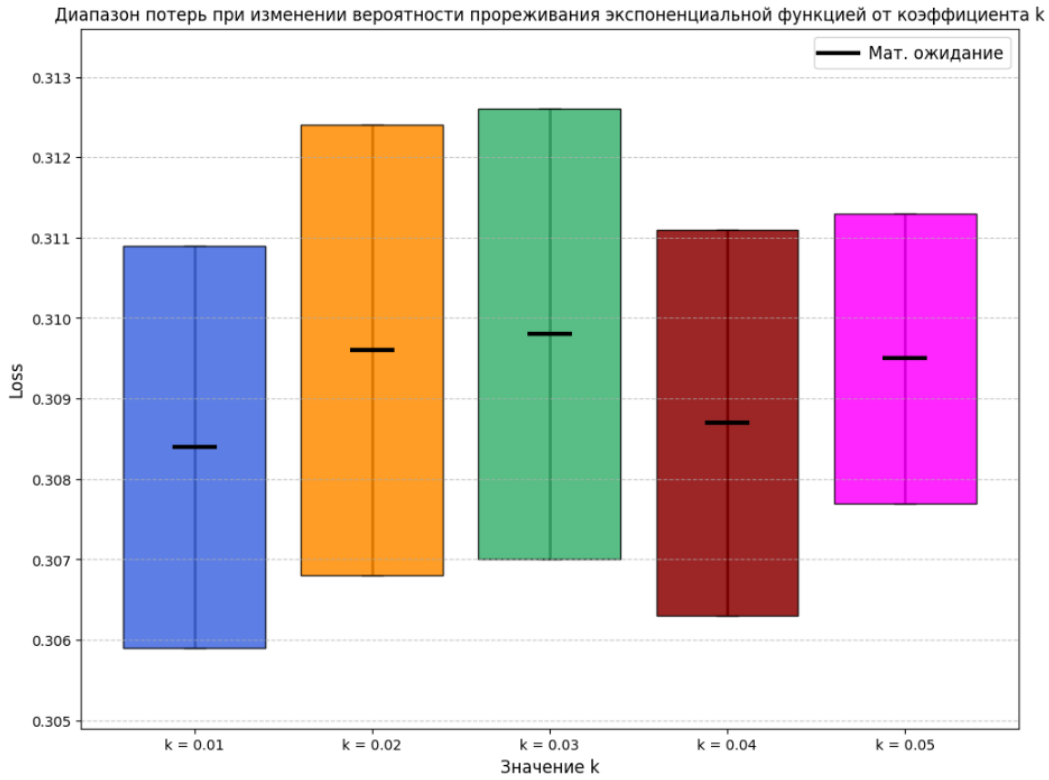


Рисунок 5. Гистограммы потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

Промежуточный вывод к п. 3.1.4: из табл. 4 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}01$, что подтверждается гистограммой на рис. 5.

3.1.5. Сравнение результатов пп. 3.1.1 – 3.1.4. с результатом изучения нейронной сети с регуляризацией классическим прореживанием с постоянной вероятностью, равной 0,5.

Сводка результатов обучения с наименьшими потерями и их сравнение с результатом обучения с использованием классического Dropout			
Вид функции + значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
Классический Dropout	0,3682	0,0028	0,371
Линейная функция $k = 0{,}0026$	0,3092	0,0022	0,3114
Полиномиальная функция $k = 0{,}00032$	0,3093	0,0024	0,3117
Логарифмическая функция $k = 0{,}032$	0,3099	0,0016	0,3115
Экспоненциальная функция $k = 0{,}01$	0,3084	0,0025	0,3109

Таблица 5. Результаты потерь при регуляризации затухающим прореживанием от значения k

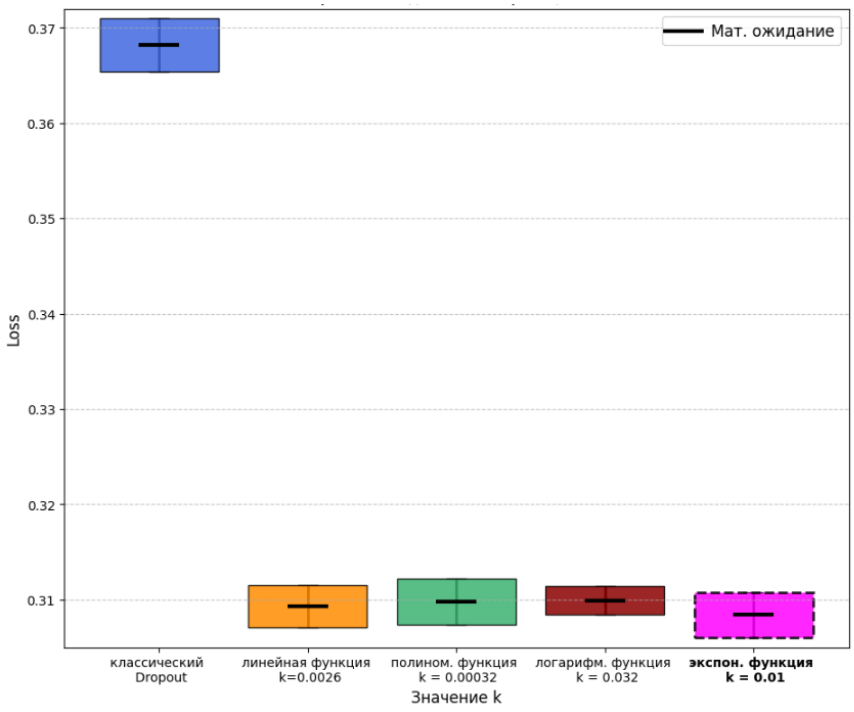


Рисунок 6. Гистограммы потерь при регуляризации затухающим прореживанием от значения k

Итоговый вывод по классификации фильмов на жанры: из результатов в табл. 5, а также из гистограммы на рис. 6 видим, что наименьшие потери достигаются при экспоненциальной функции с коэффициентом $k = 0{,}01$.

3.2. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели бинарной классификации изображений.

Для бинарной классификации изображений использовалась модель вида keras.MobileNetV2, т.к она уже предобучена на датасете ImageNet. К ней будет добавлено 2 слоя. Первый слой имеет вид Dense, состоит из 256 нейронов, имеет активационную функцию вида Relu, а также нейроны в нем могут отключаться с начальной вероятностью $p_{start} = 0{,}5$; которая потом убывает по одной из упомянутых в п.3. функции. Последний, выходной слой также имеет вид Dense, число нейронов в нем равно количеству классов изображений.

Функция потерь в этой модели имеет вид ‘binary_crossentropy’, а алгоритм оптимизации весов нейросети имеет вид ‘RMSprop’. Обучение будет разбито на 2 этапа: первые 20 эпох веса основная модель – заморожена, обучаться будут только дополнительные слои. После этого происходит разморозка базовой модели и происходит обучение вместе с базовой моделью на протяжении 10 эпох.

3.2.1. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием линейной функции.

$P(n,k) = 0{,}5 - nk$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}0026$	0,0723	0,0161	0,0884
$k = 0{,}0052$	0,0769	0,0058	0,0827
$k = 0{,}0078$	0,0872	0,0134	0,1006
$k = 0{,}0104$	0,0832	0,0146	0,0978
$k = 0{,}013$	0,0696	0,0105	0,0801

Таблица 6. Результаты потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

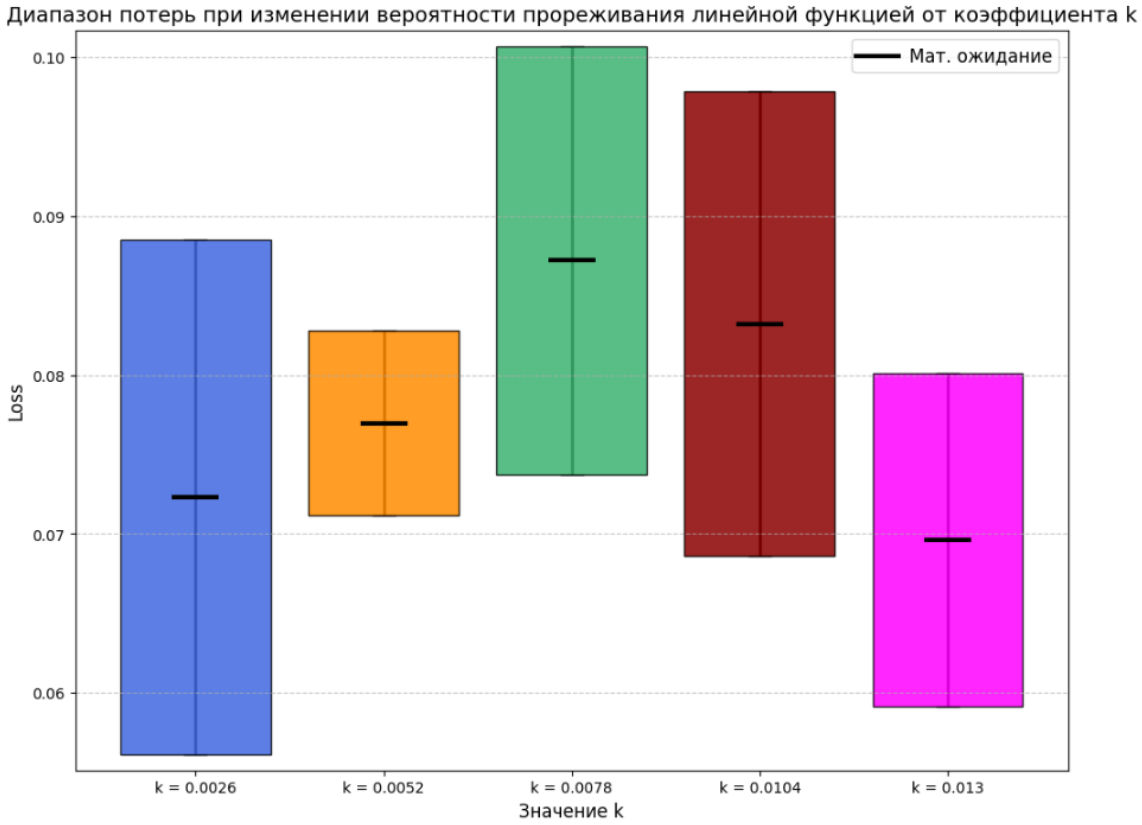


Рисунок 7. Гистограммы потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

Промежуточный вывод к п. 3.2.1: из табл. 6 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}013$, что подтверждается гистограммой на рис. 7.

3.2.2. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием полиномиальной функции

$P(n,k) = 0{,}5 - n^2 k$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}00008$	0,0784	0,0186	0,0970
$k = 0{,}00016$	0,081	0,0208	0,1018
$k = 0{,}00024$	0,0775	0,025	0,1025
$k = 0{,}00032$	0,0843	0,0151	0,0994

$k = 0{,}0004$	0,0887	0,0076	0,0963

Таблица 7. Результаты потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

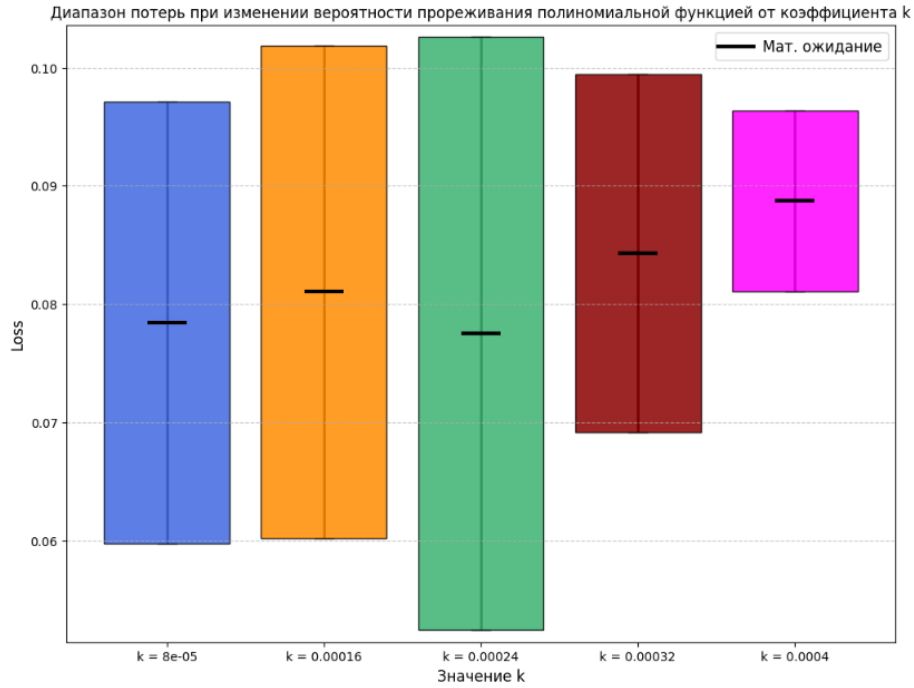


Рисунок 8. Гистограммы потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

Промежуточный вывод к п. 3.2.2: из табл. 7 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}0004$.

3.2.3. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием логарифмической функции

$P(n,k) = 0{,}5 - k \cdot \log_2(n+1)$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}016$	0,0853	0,0095	0,0948
$k = 0{,}032$	0,0722	0,0077	0,0799
$k = 0{,}048$	0,088	0,0201	0,1081
$k = 0{,}064$	0,0806	0,019	0,0996
$k = 0{,}08$	0,0885	0,0173	0,1058

Таблица 8. Результаты потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

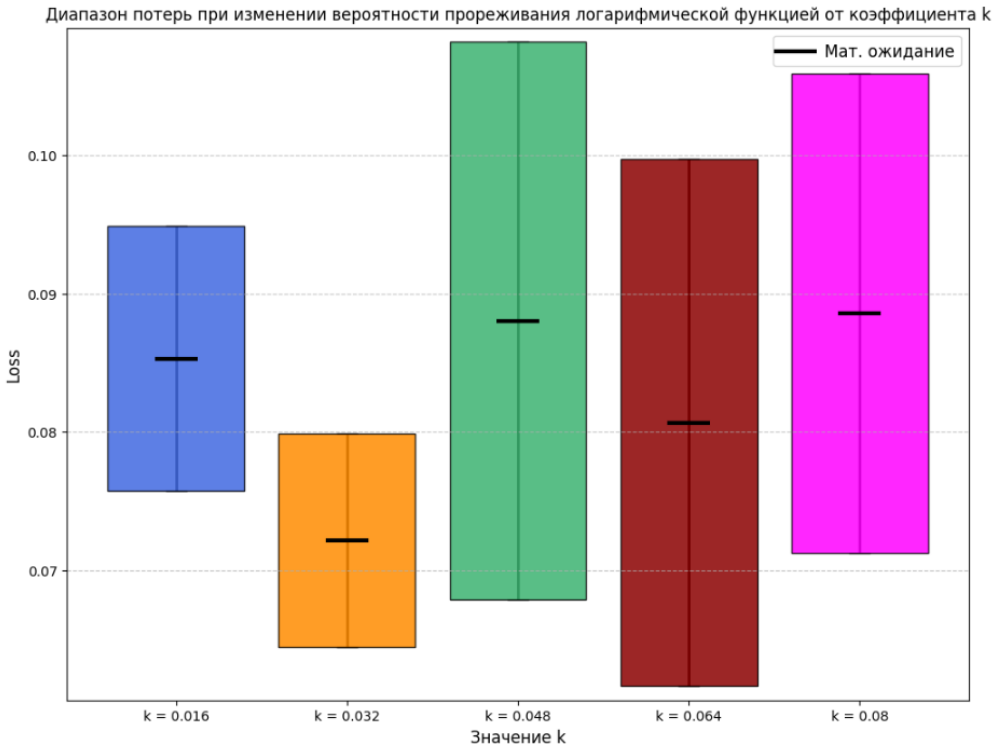


Рисунок 9. Гистограммы потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

Промежуточный вывод к п. 3.2.3: из табл. 8 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}032$. Это-же видно на гистограмме на рис. 9.

3.2.4. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием экспоненциальной функции.

$P(n,k) = 0{,}5e^{-k \cdot n}$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}01$	0,0731	0,0091	0,0822
$k = 0{,}02$	0,0826	0,0182	0,1008
$k = 0{,}03$	0,0776	0,024	0,1016
$k = 0{,}04$	0,0711	0,0174	0,0885
$k = 0{,}05$	0,0801	0,0107	0,0908

Таблица 9. Результаты потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

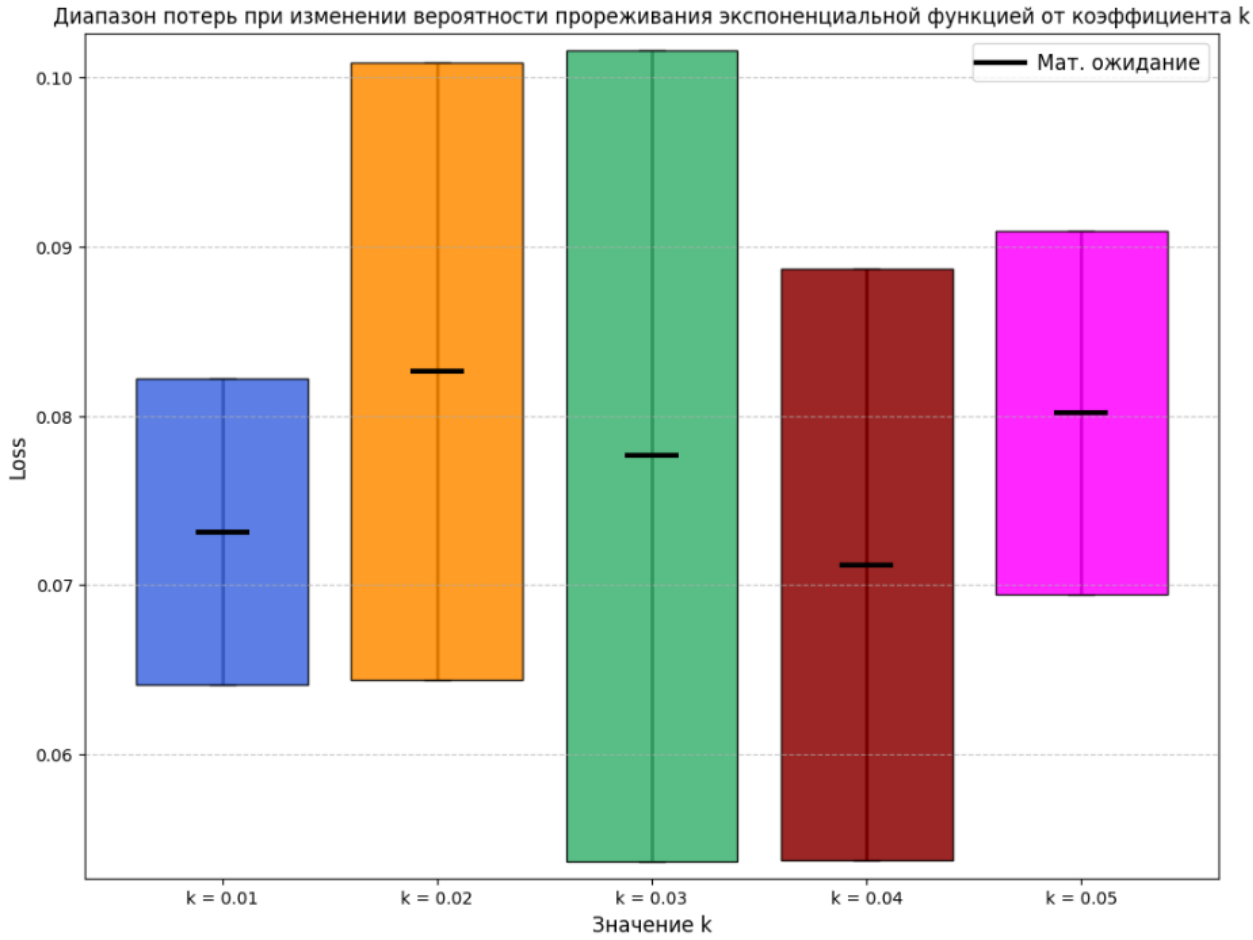


Рисунок 10. Гистограммы потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

Промежуточный вывод 3.2.4: из табл. 9 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* =$ 0,01. При этом на гистограмме на рис. 10 видно, что несмотря на то, что мат. ожидание потерь при k = 0,04 меньше, разница дисперсий сильно играет в пользу эксперимента с коэффициентом k = 0,016.

3.2.5. Сравнение результатов пп. 3.2.1 – 3.2.4. с результатом изучения нейронной сети с регуляризацией классическим прореживанием с постоянной вероятностью, равной 0,5.

Сводка результатов обучения с наименьшими потерями и их сравнение с результатом обучения с использованием классического Dropout			
Вид функции + значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
Классический Dropout	0,0909	0,0005	0,0914

Линейная функция $k = 0{,}013$	0,0696	0,0105	0,0801
Полиномиальная функция $k = 0{,}0004$	0,0887	0,0076	0,0963
Логарифмическая функция $k = 0{,}032$	0,0722	0,0077	0,0799
Экспоненциальная функция $k = 0{,}01$	0,0731	0,0091	0,0822

Таблица 10. Результаты потерь при регуляризации затухающим прореживанием от значения k

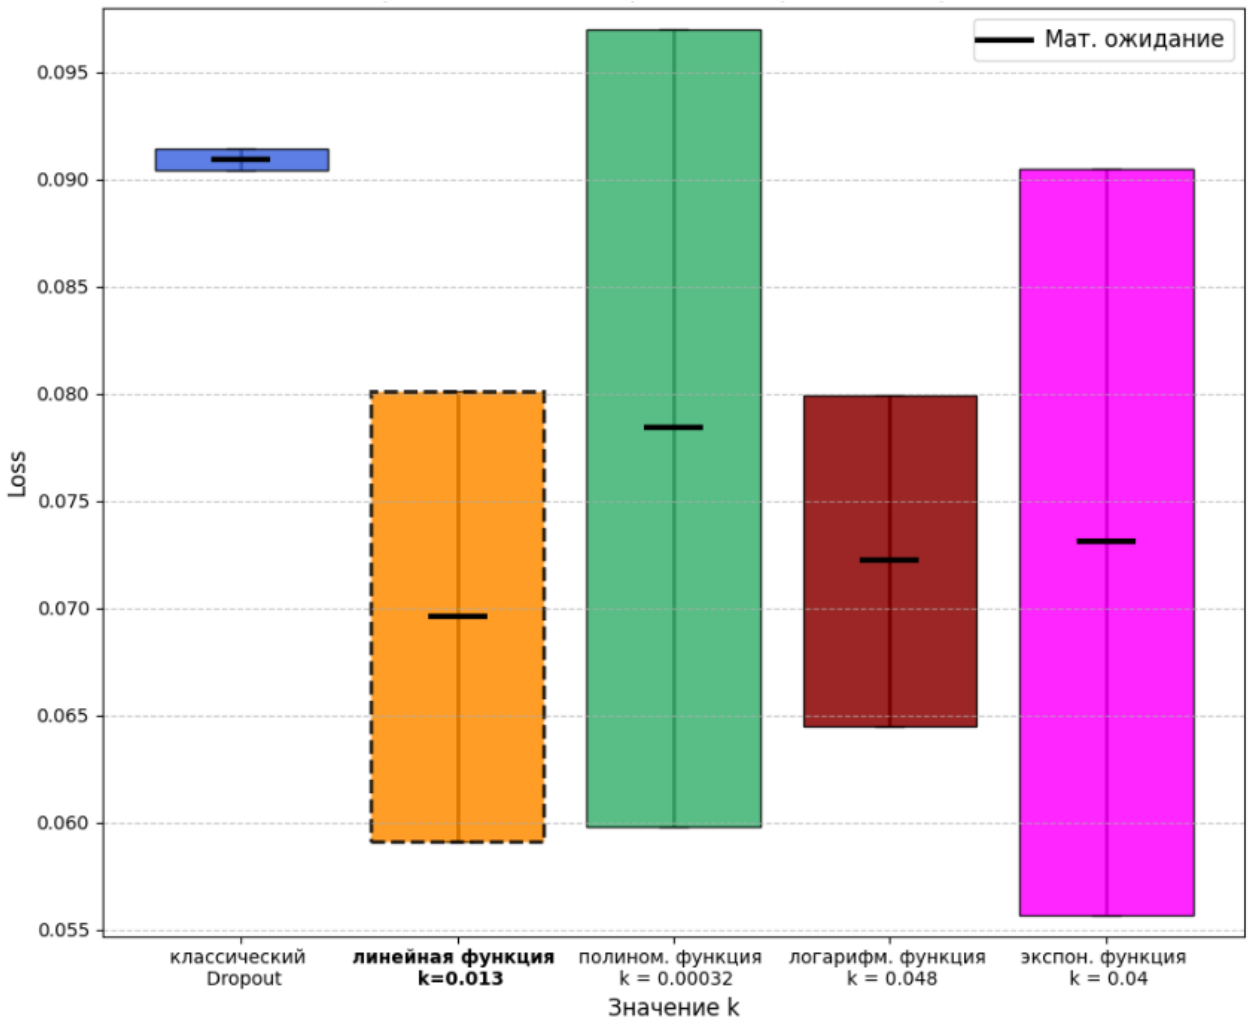


Рисунок 11. Гистограммы потерь при регуляризации затухающим прореживанием от значения k

Итоговый вывод по бинарной классификации изображений: из результатов в табл. 10, а также из гистограммы на рис. 11 видим, что наименьшие потери достигаются при линейной функции с коэффициентом $k = 0{,}013$.

3.3. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели многоклассовой классификации изображений.

Для многоклассовой классификации изображений использовалась модель вида keras.MobileNetV2, т.к она уже предобучена на датасете ImageNet. К ней будет добавлено 2 слоя. Первый слой имеет вид Dense, состоит из 256 нейронов, имеет активационную функцию вида Relu, а также нейроны в нем могут отключаться с начальной вероятностью $p_{start} = 0{,}5$; которая потом убывает по одной из упомянутых в п.3. функции. Последний, выходной слой также имеет вид Dense, число нейронов в нем равно количеству классов изображений.

Функция потерь в этой модели имеет вид '_crossentropy', а алгоритм оптимизации весов нейросети имеет вид 'RMSprop'. Обучение будет разбито на 2 этапа: первые 20 эпох веса основная модель – заморожена, обучаться будут только дополнительные слои. После этого происходит разморозка базовой модели и происходит обучение вместе с базовой моделью на протяжении 10 эпох.

3.3.1. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием линейной функции

$P(n,k) = 0{,}5 - nk$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}0026$	0,4111	0,0199	0,4310
$k = 0{,}0052$	0,3973	0,0175	0,4148
$k = 0{,}0078$	0,4001	0,0074	0,4075
$k = 0{,}0104$	0,3943	0,0144	0,4087
$k = 0{,}0013$	0,397	0,0136	0,4106

Таблица 11. Результаты потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

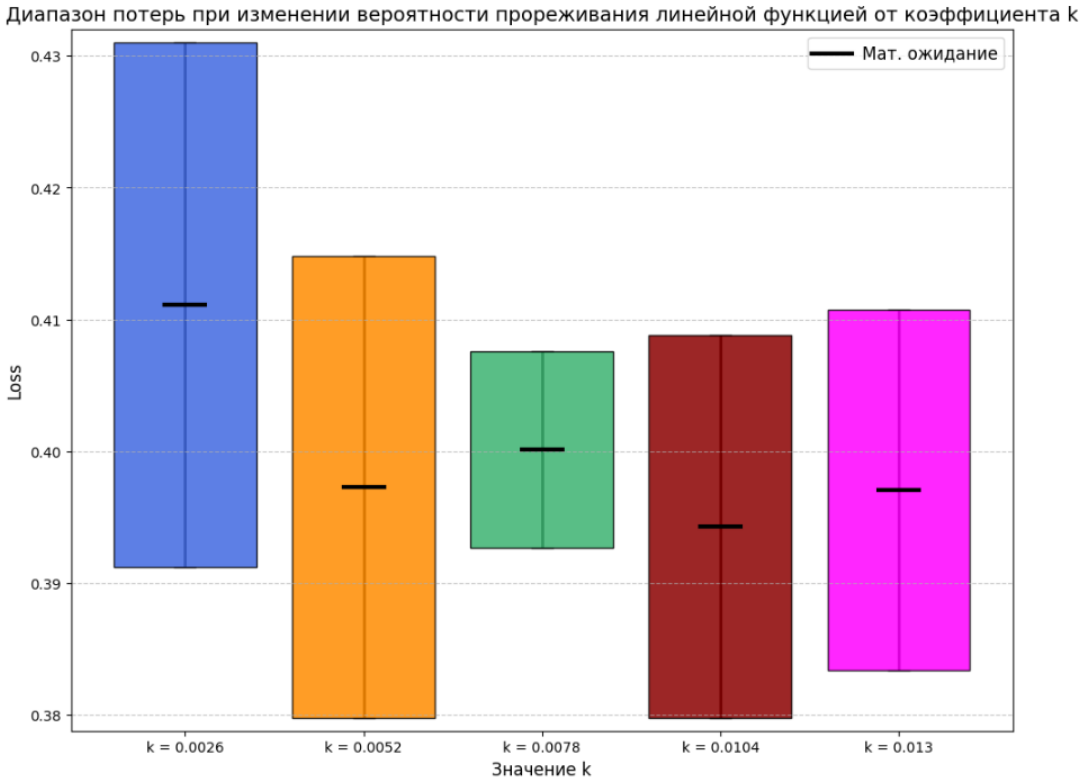


Рисунок 12. Гистограммы потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

Промежуточный вывод к п. 3.3.1: из табл. 11 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}0104$, что подтверждается гистограммой на рис. 12.

3.3.2. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием полиномиальной функции

$P(n,k) = 0{,}5 - n^2k$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}00008$	0,4084	0,0096	0,4180
$k = 0{,}00016$	0,4066	0,015	0,4216
$k = 0{,}00024$	0,3942	0,0108	0,4050
$k = 0{,}00032$	0,3959	0,0139	0,4098
$k = 0{,}0004$	0,4049	0,0091	0,4140

Таблица 12. Результаты потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

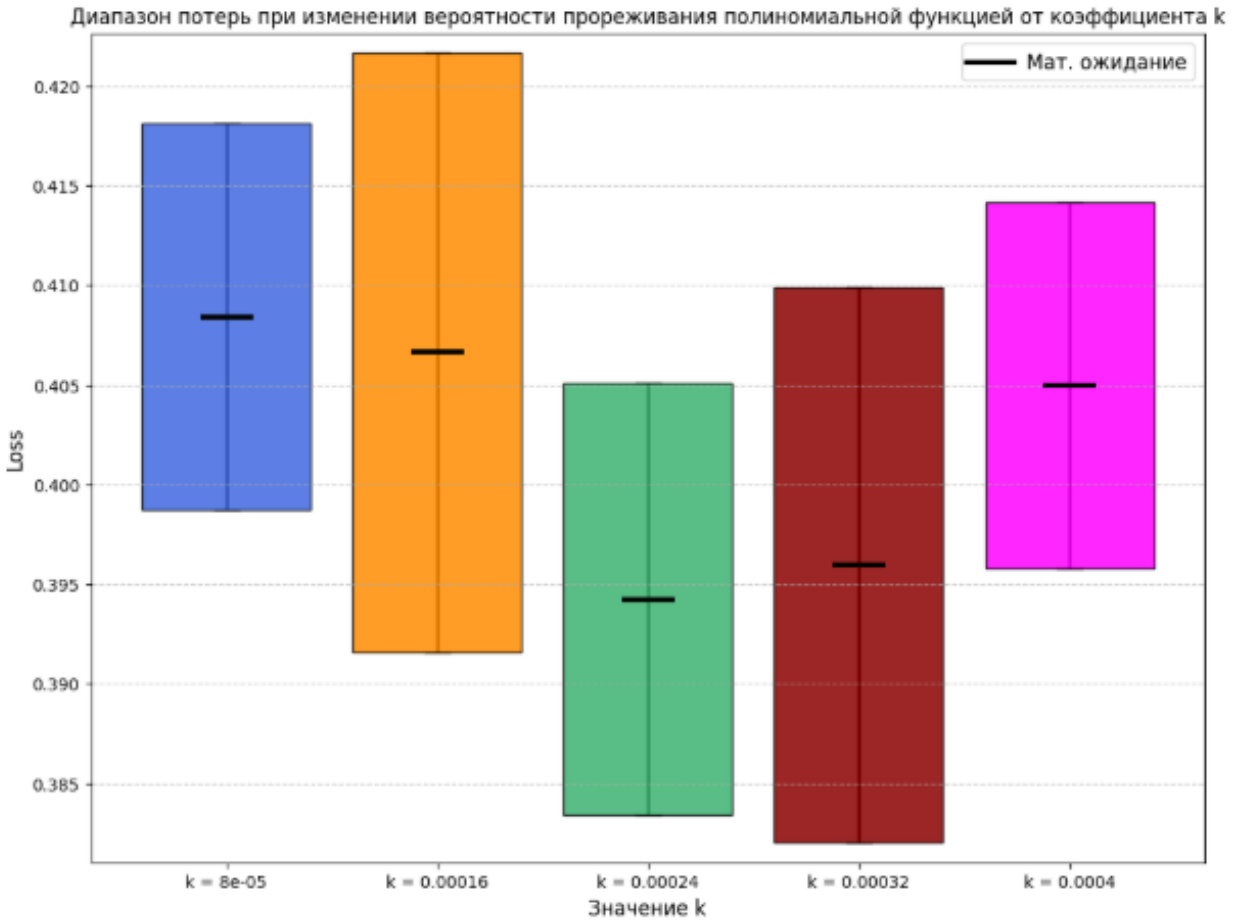


Рисунок 13. Гистограммы потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

Промежуточный вывод к п. 3.3.2: из табл. 12 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}00024$, что подтверждается гистограммой на рис. 13.

3.3.3. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием логарифмической функции

$P(n,k) = 0{,}5 - k \cdot \log_2(n+1)$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}016$	0,3952	0,0135	0,4087
$k = 0{,}032$	0,3941	0,0107	0,4048
$k = 0{,}048$	0,3942	0,0119	0,4061
$k = 0{,}064$	0,4078	0,0107	0,4185

$k = 0{,}08$	0,405	0,0091	0,4141

Таблица 13. Результаты потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

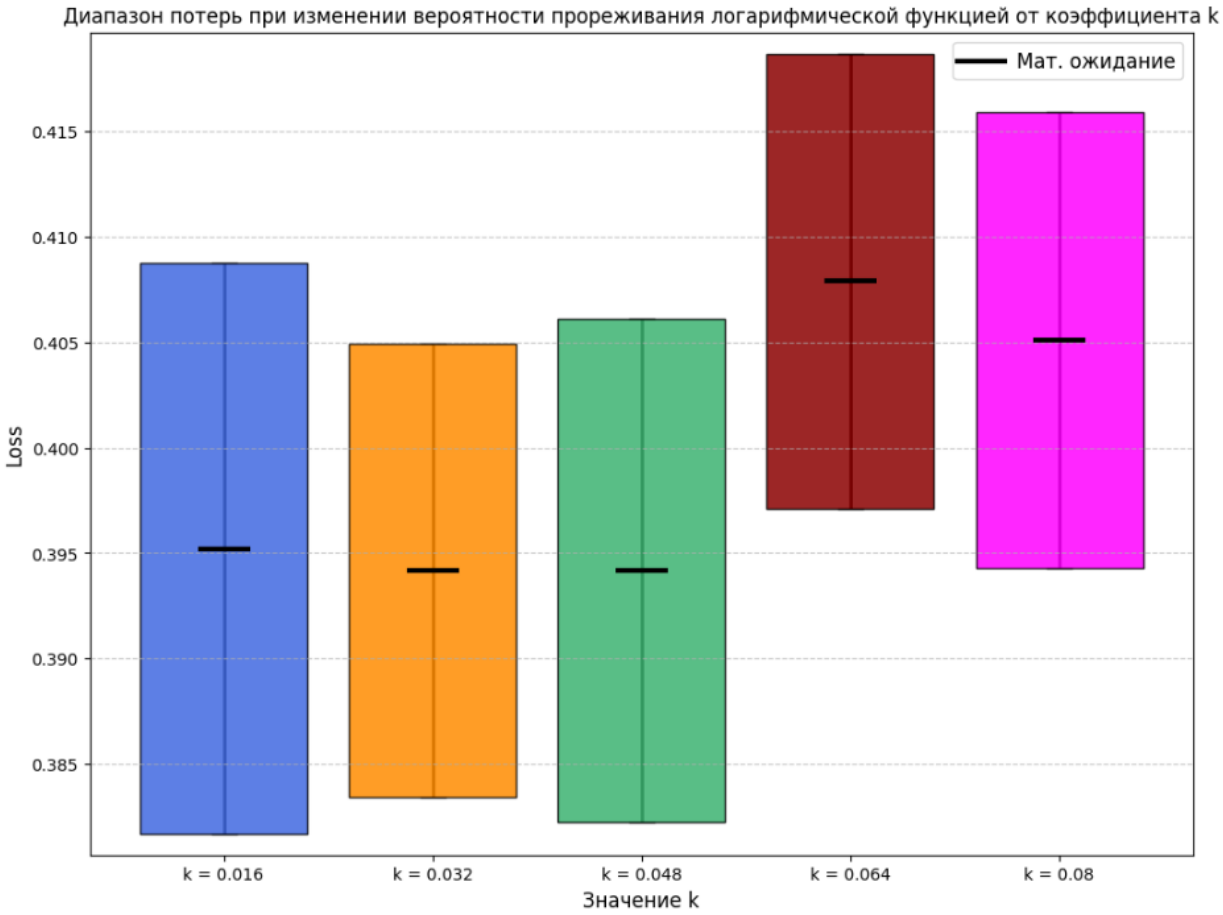


Рисунок 14. Гистограммы потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

Промежуточный вывод к п. 3.3.3: из табл. 13 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}032$. Это-же видно на гистограмме на рис. 14: значения потерь J при $k = 0{,}048$ и при $k = 0{,}032$ получились близки друг к другу, но с учетом того, что дисперсия при $k = 0{,}048$ получилась выше, то предпочтительнее в дальнейшем рассматривать коэффициент $k_0^* = 0{,}032$.

3.3.4. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием экспоненциальной функции

$P(n,k) = 0{,}5e^{-k \cdot n}$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}01$	0,4013	0,0189	0,4202

$k = 0{,}02$	0,4043	0,0107	0,4150
$k = 0{,}03$	0,4048	0,0126	0,4174
$k = 0{,}04$	0,407	0,0148	0,4218
$k = 0{,}05$	0,4028	0,0075	0,4103

Таблица 14. Результаты потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

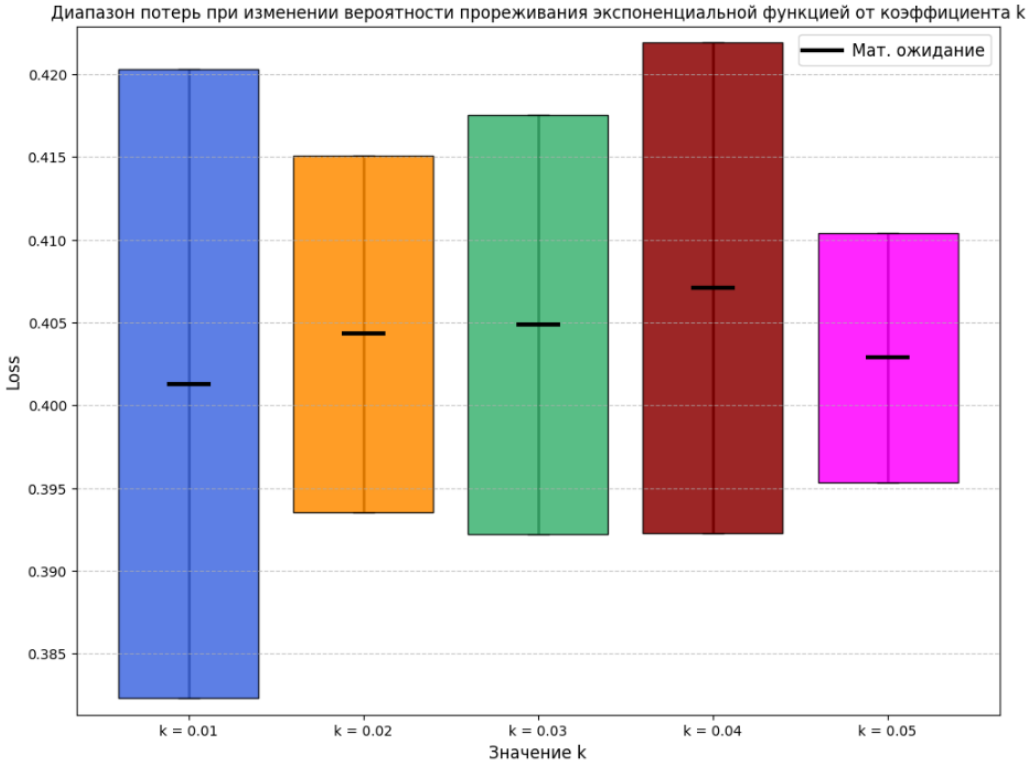


Рисунок 15. Гистограммы потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

Промежуточный вывод к п. 3.3.4: из табл. 14 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}05$, что подтверждается гистограммой на рис. 15.

3.3.5. Сравнение результатов п. 3.3.1 – 3.3.4. с результатом изучения нейронной сети с регуляризацией классическим прореживанием с постоянной вероятностью, равной 0,5.

Сводка результатов обучения с наименьшими потерями и их сравнение с результатом обучения с использованием классического Dropout			
Вид функции + значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
Классический Dropout	0,3939	0,0188	0,4127

Линейная функция $k = 0{,}0078$	0,3943	0,0144	0,4075
Полиномиальная функция $k = 0{,}00024$	0,4001	0,0074	0,3996
Логарифмическая функция $k = 0{,}032$	0,3941	0,0107	0,39945
Экспоненциальная функция $k = 0{,}01$	0,4028	0,0075	0,40655

Таблица 15. Результаты потерь при регуляризации затухающим прореживанием от значения k

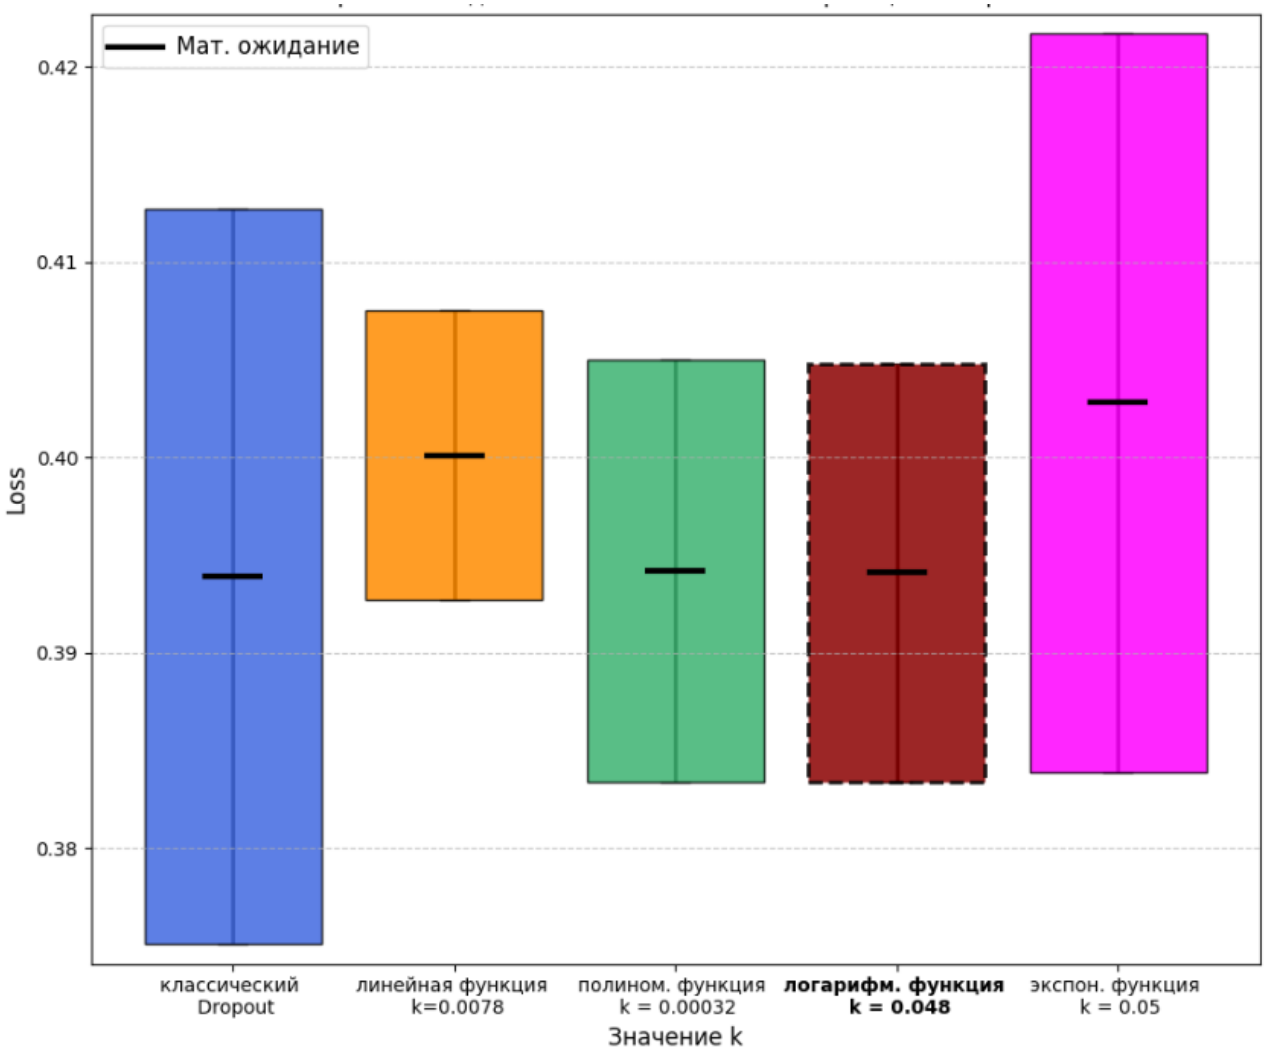


Рисунок 16. Гистограммы потерь при регуляризации затухающим прореживанием от значения k

Итоговый вывод по многоклассовой классификации изображений: из табл. 15 и гистограммы на рис. 16 видим, что схожее с классическим Dropout мат.

ожидание потерь получается при использовании логарифмической функции с коэффициентом k = 0,048. Но дисперсия потерь при использовании логарифмической функции с коэффициентом k = 0,048 получаются сильно меньше, поэтому предпочтительнее использовать логарифмическую функцию с коэффициентом k = 0,048.

3.4. Исследование влияния затухающего Dropout на потери, получившиеся при обучении модели классификации звуков.

Для многоклассовой классификации изображений использовалась модель вида keras.MobileNetV2. Для её использования необходимо преобразовать данные звуковых сигналов в двумерный массив: 1 секунда звука преобразуется в тепловую карту частот (спектрограмму) размером 128 на 128. К модели будет добавлена возможность нейронов отключаться с начальной вероятностью $p_{start} = 0{,}5$; которая потом убывает по одной из упомянутых в п.3. функции. Последний, выходной слой также имеет вид Dense, число нейронов в нем равно количеству классов изображений, с функцией активации ‘Softmax’.

Функция потерь в этой модели имеет вид ‘binary_crossentropy’, а алгоритм оптимизации весов нейросети имеет вид ‘RMSprop’. Обучение будет разбито на 2 этапа: первые 10 эпох веса основной модели заморожены, обучаться будут только дополнительные слои. После этого происходит разморозка базовой модели и происходит обучение на протяжении 20 эпох.

3.4.1. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием линейной функции

$P(n,k) = 0{,}5 - nk$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}0026$	1,7941	0,2135	2,0076
$k = 0{,}0052$	2,0717	0,2087	2,2804
$k = 0{,}0078$	1,8140	0,2185	2,0325

$k = 0{,}0104$	1,9591	0,2770	2,2361
$k = 0{,}013$	1,7743	0,1496	1,9239

Таблица 16. Результаты потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

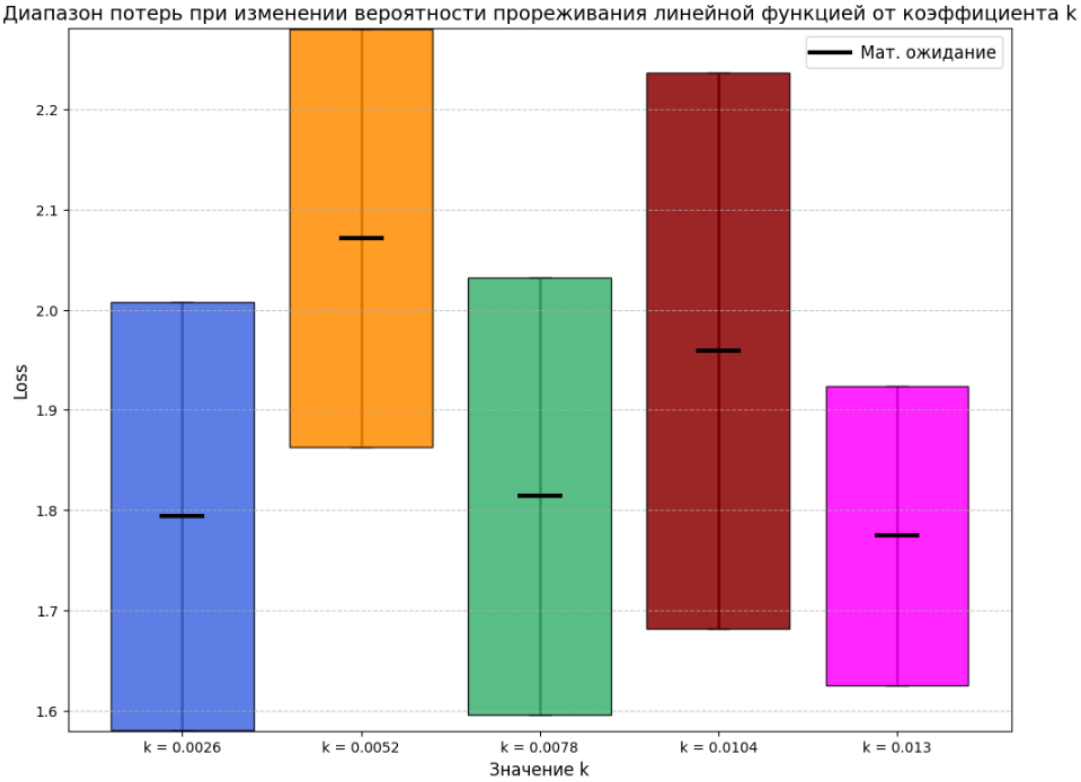


Рисунок 17. Гистограммы потерь при регуляризации затухающим прореживанием с использованием линейной функции от значения k

Промежуточный вывод 3.4.1: из табл. 16 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}013$, что подтверждается гистограммой на рис. 17.

3.4.2. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием полиномиальной функции

$P(n,k) = 0{,}5 - n^2k$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}00008$	1,9878	0,3099	2,2977
$k = 0{,}00016$	1,8948	0,2804	2,1752
$k = 0{,}00024$	2,0057	0,2697	2,2754
$k = 0{,}00032$	1,7331	0,1523	1,8854
$k = 0{,}0004$	1,9090	0,1902	2,0992

Таблица 17. Результаты потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

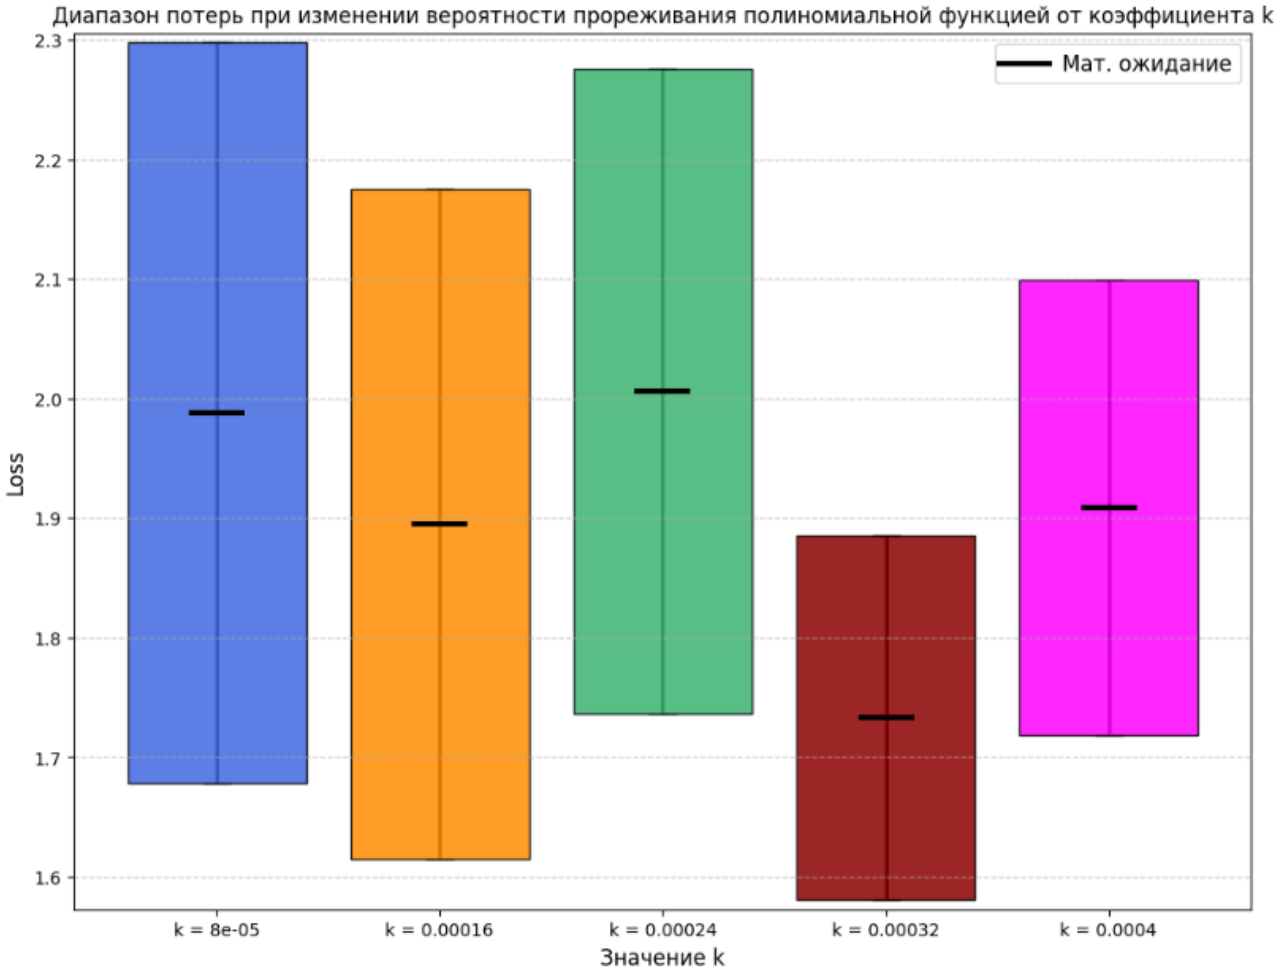


Рисунок 18. Гистограммы потерь при регуляризации затухающим прореживанием с использованием полиномиальной функции от значения k

Промежуточный вывод к п. 3.4.2: из табл. 17 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}013$, что подтверждается гистограммой на рис. 18.

3.4.3. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием логарифмической функции

$P(n,k) = 0{,}5 - k \cdot \log_2(n+1)$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}016$	1,9863	0,1682	2,1545
$k = 0{,}032$	1,8539	0,2225	2,0764
$k = 0{,}048$	2,0719	0,2593	2,3312
$k = 0{,}064$	1,9979	0,2168	2,2147
$k = 0{,}08$	1,9982	0,2820	2,2802

Таблица 18. Результаты потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

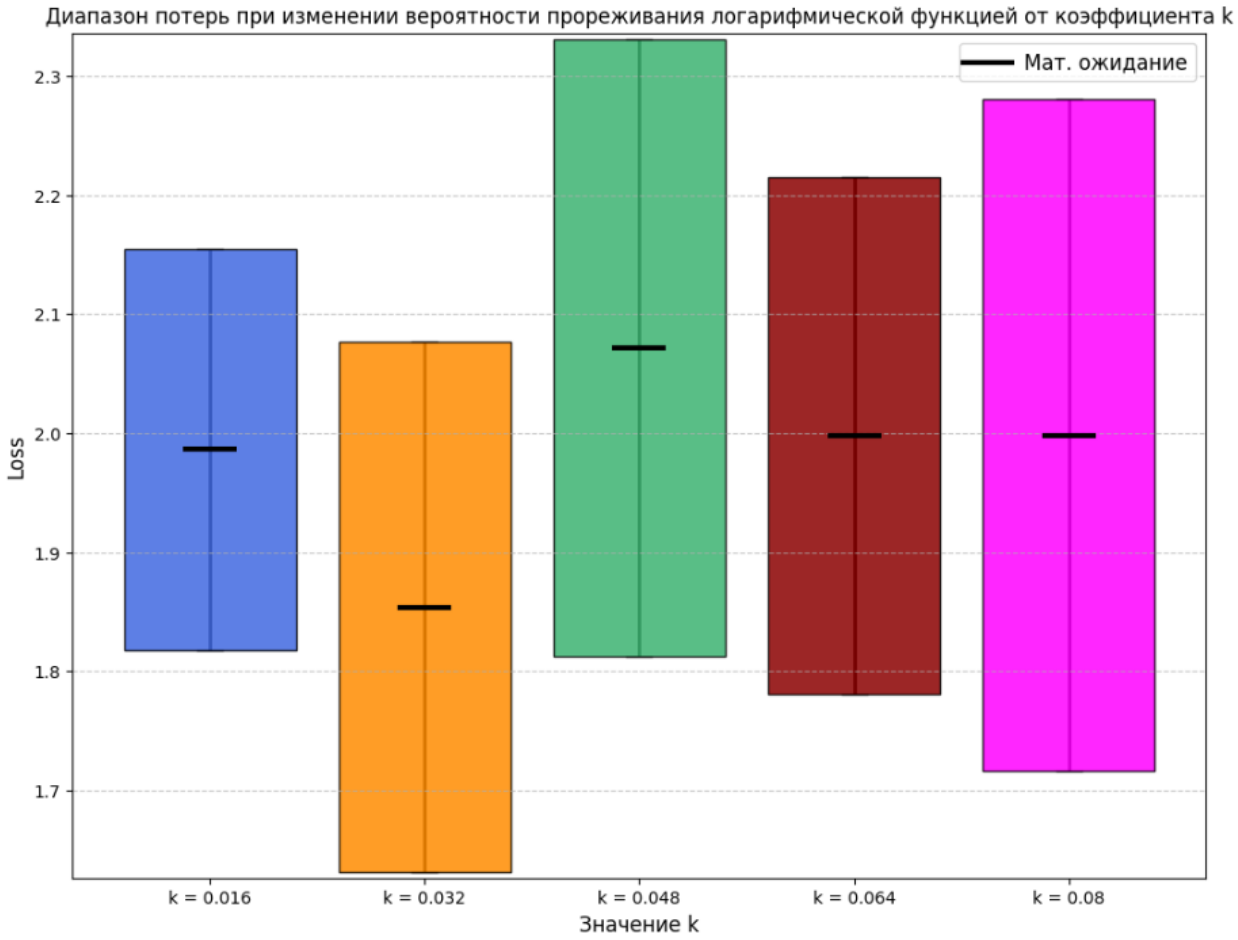


Рисунок 19. Гистограммы потерь при регуляризации затухающим прореживанием с использованием логарифмической функции от значения k

Промежуточный вывод к п. 3.4.3: из табл. 18 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}032$, что подтверждается гистограммой на рис. 19.

3.4.4. Результаты обучения при использовании при регуляризации затухающим прореживанием с использованием экспоненциальной функции

$P(n,k) = 0{,}5e^{-k \cdot n}$			
Значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
$k = 0{,}01$	1,9097	0,2496	2,1593
$k = 0{,}02$	1,8707	0,2847	2,1554
$k = 0{,}03$	1,9476	0,2083	2,1559
$k = 0{,}04$	1,8036	0,2389	2,0425
$k = 0{,}05$	2,0436	0,2756	2,3192

Таблица 19. Результаты потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

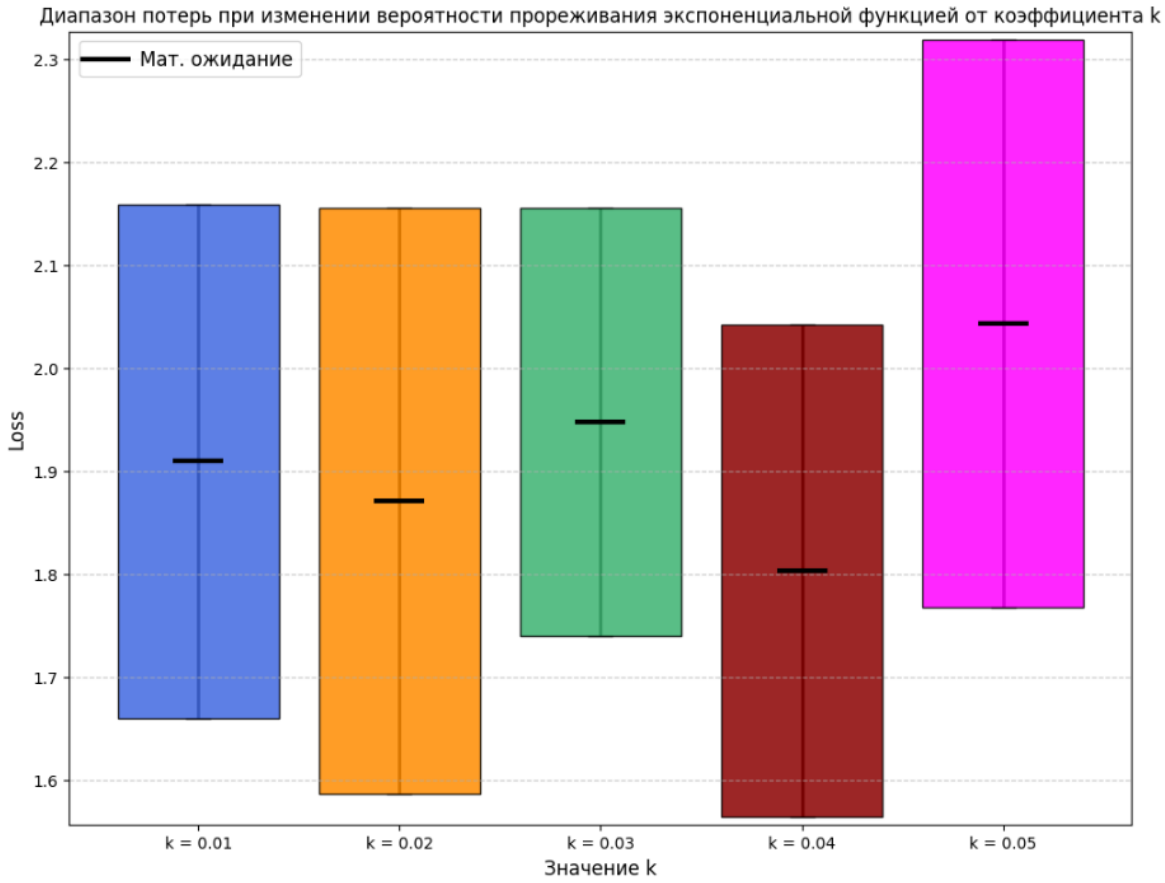


Рисунок 20. Гистограммы потерь при регуляризации затухающим прореживанием с использованием экспоненциальной функции от значения k

Промежуточный вывод к п. 3.4.4: из табл. 19 видим, что наименьшее значение целевая функция принимает свое значение при $k_0^* = 0{,}04$, что подтверждается гистограммой на рис. 20.

3.4.5. Сравнение результатов п. 3.4.1 – 3.4.4. с результатом изучения нейронной сети с регуляризацией классическим прореживанием с постоянной вероятностью, равной 0,5.

Сводка результатов обучения с наименьшими потерями и их сравнение с результатом обучения с использованием классического Dropout			
Вид функции + значение k	Мат. ожидание потерь по 4 экспериментам	Дисперсия потерь по 4 экспериментам	Оценка J(k)
Классический Dropout	0,9967	0,0178	1,0145
Линейная функция $k = 0{,}013$	1,7743	0,1496	1,9239

Полиномиальная функция $k = 0{,}00032$	1,7331	0,1523	1,8854
Логарифмическая функция $k = 0{,}032$	1,8539	0,2225	2,0764
Экспоненциальная функция $k = 0{,}04$	1,8036	0,2389	2,0425

Таблица 20. Результаты потерь при регуляризации затухающим прореживанием от значения k

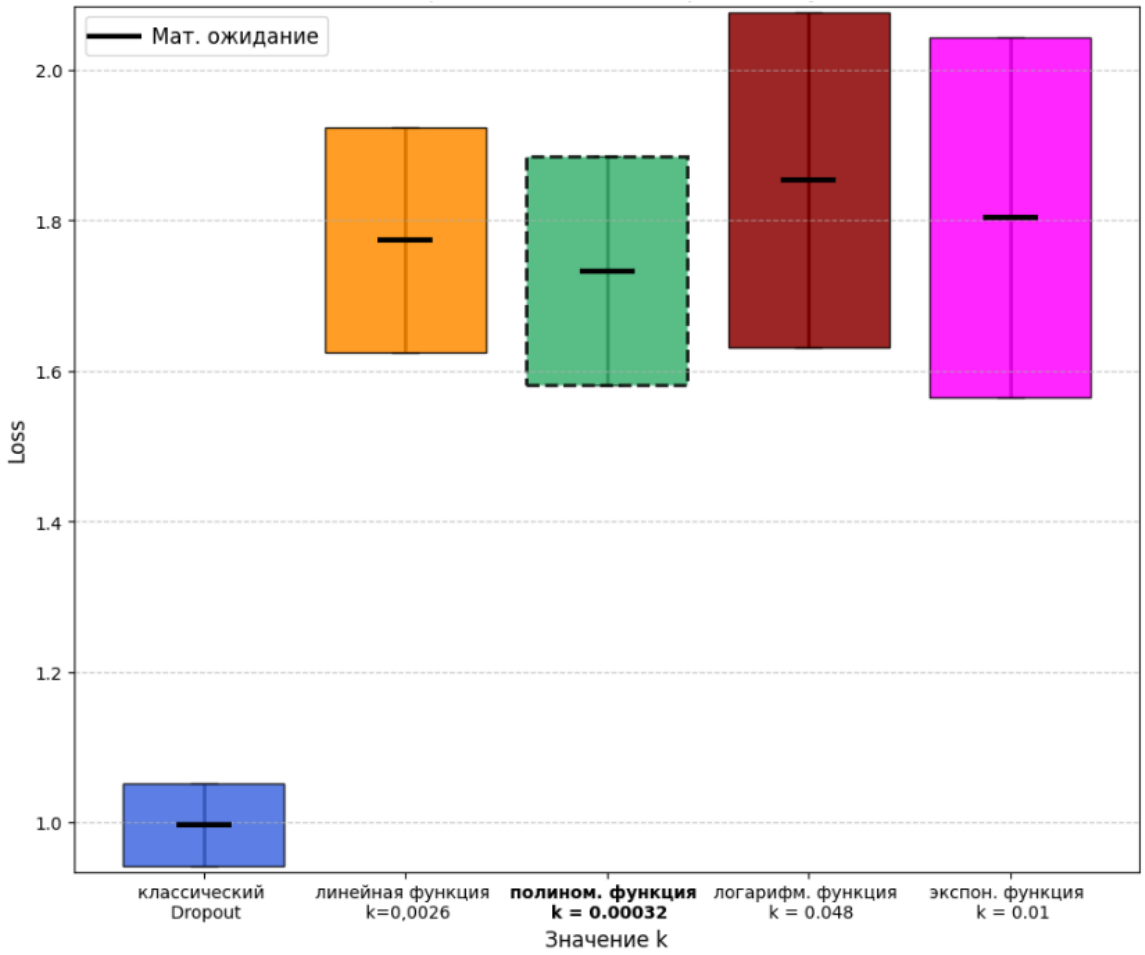


Рисунок 21. Гистограммы потерь при регуляризации затухающим прореживанием от значения k

Итоговый вывод по классификации звуков: для задачи классификации звуковых команд регуляризация методом затухающего Dropout не дает значительного преимущества в уменьшении потерь при обучении, поэтому в этой ситуации будет более уместно использовать классический Dropout.

4. ЗАКЛЮЧЕНИЕ

В данной выпускной квалификационной работе исследована работа затухающего Dropout для нейросетей, ориентированных на решение задач классификации.

Были сформулированы следующие выводы:

- Для задачи классификации текстов наименьшие потери получились при обучении модели с использованием затухающего Dropout при экспоненциальной функции с параметром $k = 0{,}01$.
- Для задачи классификации наименьшие потери получились при обучении модели с использованием затухающего Dropout при линейной функции с параметром $k = 0{,}013$.
- Для задачи многоклассовой классификации изображений схожее с классическим Dropout мат. ожидание потерь получается при использовании логарифмической функции с коэффициентом $k = 0{,}048$. Но дисперсия потерь при использовании логарифмической функции с коэффициентом $k = 0{,}048$ получаются сильно меньше, поэтому предпочтительнее использовать логарифмическую функцию с коэффициентом $k = 0{,}048$.
- Для задачи классификации звуковых команд регуляризация методом затухающего Dropout не дает значительного преимущества в уменьшении потерь при обучении, поэтому в этой ситуации будет более уместно использовать классический Dropout.

В качестве направлений для дальнейшего развития темы представляется перспективным исследование предложенного математического аппарата на более сложных архитектурах и иных типах данных, а также внедрение адаптивного затухания, при котором коэффициент затухания k зависит не от номера эпохи, а от текущего значения функции потерь.

5. СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Deep Learning with Python SECOND EDITION – FRANÇOIS CHOLLET

2. Machine Learning with PyTorch and Scikit-Learn – Sebastian Raschka Yuxi (Hayden) Liu Vahid Mirjalili

3. Adaptive Dropout: Unleashing Dropout across Layers for Generalizable Image Super-Resolution

4. Simon J.D. Prince – UNDERSTANDING DEEP LEARNING

5. Deep Learning – Ian Goodfellow, Yoshua Bengio, Aaron Courville

6. Vaswani et al. – Ashish Vaswani